Como enseñar a las máquinas a leer y comprender

Sanchez Ramos, Lesly Dashiel
Universidad Nacional
de Ingeniería
Lima, Perú
lesly.sanchez.r@uni.pe

Yagi Vasquéz, Gladys Alesandra
Universidad Nacional
de Ingeniería
Lima, Perú
gladys.yagi.v@uni.pe

***Resumen*—Los modelos RNN utilizados en máquinas con el propósito de enseñarles a leer y comprender han ido en aumento en los últimos años. Sin embargo, sigue siendo un reto implementar un modelo completamente fiable para esta clase de propósito. Además, esta clase de modelo trabajan con un gran conjunto de datos.**

En el presente trabajo se implementó un modelo basado en RNN para enseñarle a una máquina a leer y comprender un libro de niños.

Palabras Claves: NLP, RNN, Seq2Seq, CBT.

I. INTRODUCCIÓN:

Los avances en los algoritmos de Deep Learning, con el objetivo de darle a una máquina la capacidad de leer y comprender el lenguaje en documentos, han ido en aumento [1]. Esto se debe a que en los últimos años los conjuntos de datos para entrenamiento y prueba a gran escala para evaluar este tipo de capacidad han aumentado, así como la creación de frameworks, tales como ParlAI, que nos ofrecen una amplia gama de herramientas para entrenar modelos de lectura y comprensión así como modelos de diálogo y respuesta.

La capacidad de las máquinas para leer y comprender un determinado documento puede ser testeada mediante su habilidad para poder responder preguntas y respuestas por medio de contenido de documentos, predecir palabras en historias incompletas, resumir reseñas de productos o predicir si una premisa y su hipótesis se contradicen o son neutrales entre sí.

Teaching Machines to Read and Comprehend [1] es uno de los papers más famosos y mencionados que implementa modelos basados en redes neuronales para probar la capacidad de un sistema para responder preguntas planteadas sobre el contenido de un documento que han visto. Uno de esos modelos es el Deep LSTM Reader, donde por medio un encoder y decoder Deep LSTM, se procesan las consultas y luego el documento, dando como resultado un modelo que procesa cada par de consultas del documento como única secuencia larga.
Un conjunto de datos famoso por ser utilizado para la comprensión lectora de las máquinas es el CNN/Daily Mail.

Original Version	**Anonymised Version**
Context	
The BBC producer allegedly struck by Jeremy Clarkson will not press charges against the "Top Gear" host, his lawyer said Friday. Clarkson, who hosted one of the most-watched television shows in the world, was dropped by the BBC Wednesday after an internal investigation by the British broadcaster found he had subjected producer Oisin Tymon "to an unprovoked physical and verbal attack." ...	the *ent381* producer allegedly struck by *ent212* will not press charges against the " *ent153* " host , his lawyer said friday . *ent212* , who hosted one of the most - watched television shows in the world , was dropped by the *ent381* wednesday after an internal investigation by the *ent180* broadcaster found he had subjected producer *ent193* " to an unprovoked physical and verbal attack . " ...
Query	
Producer **X** will not press charges against Jeremy Clarkson, his lawyer says.	producer **X** will not press charges against *ent212* , his lawyer says .
Answer	
Oisin Tymon	*ent193*

Figura 1. Versión original y anonimizada de un artículo extraído del conjunto de datos de validación del Daily Mail. Las entidades anonimizadas están contantemente permutándose durante la prueba y entrenamiento.

De la Figura 1 podemos observar como se extraen las entidades de oraciones clave de los artículos de las noticias para ser reemplazados con espacios en blanco. Para así poder entrenar a la máquina en responder preguntas dependiendo del texto restante.

En este trabajo, se buscará analizar un modelo de red neuronal recurrente que sea capaz de completar oraciones a partir de fragmentos de un libro para niño, se pretende que esto sea posible mediante el uso del framework ParlAI, la cual también es una plataforma que nos ofrece tutoriales de como añadir nuestros propios datasets así o usar los que nos proporcionan, crear nuestros propios modelos, entrenarlos y validarlos, así como implentar agentes que se encargen de diversas tareas.

Demostraremos facilidad que tiene esta plataforma así como la eficacia de nuestro modelo para esta clase de trabajos.

II. OBJETIVO DEL ESTUDIO

Comprender y analizar las redes neuronales recurrentes y como estas permiten que una máquina pueda leer y comprender un cuento para niños.

II-A. Objetivos Específicos

1. Implementar el modelo Seq2Seq en el framework ParlAI para enseñarle a una máquina a leer y comprender.
2. Evaluar la efectividad del modelo Seq2Seq para completar oraciones de un libro para niños.

III. MARCO TEÓRICO

III-A. Natural Language Processing

El procesado del lenguaje natural (NLP) es un campo de la ciencia de la computación que se ocupa del uso de las computadoras para la extracción, interpretación, análisis y manipulación del lenguaje humano. Algo relacionado al NLP es el Question answering (QA), el cual es una tarea del NLP encargada de responder a preguntas en el lenguaje natural, aprovechando los métodos de recuperación de información y representación del conocimiento [2]. Siendo de esta manera la forma en la que la máquina aprenderá a leer y comprender .

III-B. Recurrent Neural Network

Las redes neuronales recurrentes (RNN) tienen la capacidad de modelar la información contextual en secuencias largas. Para el procesamiento del lenguaje natural se desea capturar las dependencias a largo plazo; además de mantener el orden contextual entre las palabras para resolver el significado global de un texto. Otra ventaja de las RNN es su capacidad para aprender representaciones de secuencias de longitud variable, como frases, documentos y muestras de habla [2].

III-C. Long Short-Term Memory

La memoria a largo y corto plazo (LSTM) utiliza puertas de entrada, salida y olvido para controlar la propagación del gradiente en la memoria de la red neuronal recurrente (RNN). Esto permite proteger las celdas de memoria que lleven algún estado oculto al siguiente paso. Los estados de activación permiten que la red aprenda las condiciones para cuando olvidar o mantener la información en la celda de memoria [2].

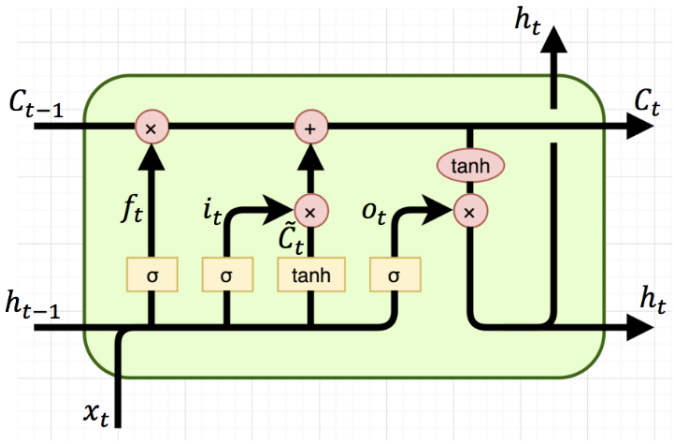

Figura 2. Diagrama de una celda LSTM

III-D. Seq2Seq

El modelo Sequence to Sequence se utiliza cuando tenemos una entrada de longitud variable que no es necesariamente una entidad asociada a otra. Un modelo Seq2Seq se compone más comunmente de dos RNN que trabajan de manera cooperativa: encoder y decoder. Ambas siendo modelos LSTM. Este modelo es usado commúnmente para máquinas de traducción, resumen de texto, modelos de conversación, predicción de palabras, y más.

III-D1. Encoder: Se encagará de codificar el input palabra por palabra en un vector de estado o de contexto (en el caso de LSTM estas son llamadas estado oculto o vectores de estado de las celdas).

III-D2. Decoder: Este es el estado oculto final por parte del codificador. Se encarga de encapsular todos los elementos de entrada para poder realizar una predicción.

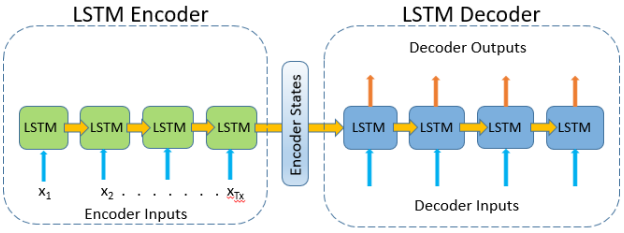

Figura 3. Modelo encoder-decoder con LSTM unidireccionales

En la Figura 3, el encoder codifica una secuencia de entrada pasándolas por las celdas LSTM, este encoder consta de los estados ocultos;luego, se pasa a la decodificación como estados iniciales junto con los

inputs del decodificador para poder hacer predicciones.

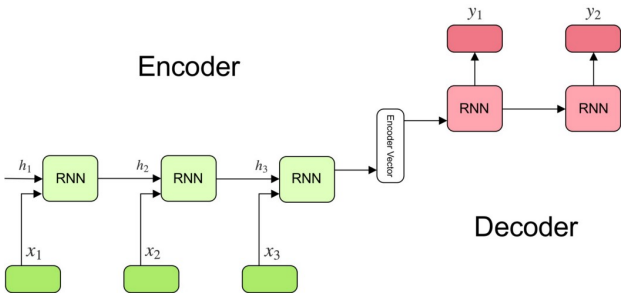

Figura 4. Encoder-decoder

Como podemos observar en la Figura 4, cada rectángulo representa una capa oculta en un paso de tiempo t.

La fórmula para calcular los elementos de salida de la capa oculta en cada paso de tiempo t es [5]:

$$h_t = f(W^{(hh)}h_{t-1} + W^{(hx)}x_t) \quad (1)$$

A continuación, se detalla los parámetros asociados a esta fórmula:

- x_1,...,x_{t-1},x_t,x_{t+1},...,x_T: Los vectores de palabras correspondientes a un documento con T palabras.
- W^{hx}: Matriz de pesos utilizada para condicionar el vector de palabras de entrada x_t.
- W^{hh}: Matriz de pesos utilizada para condicionar el vector de palabras de salida h_{t-1}.
- h_{t-1}: Salida de la función no lineal en el paso de tiempo anterior $t-1$.
- σ: Función de no lineal (sigmoide).

Además, tenemos que la función para calcular la distribución de probabilidad de salida sobre el vocabulario en cada paso del tiempo t es:

$$y_t = softmax(W^s h_t) \quad (2)$$

Donde W_S es la matriz de pesos utilizada de acuerdo al vocabulario y a la palabra de salida h_{t-1}. e y_t es la siguiente palabra predicha dado el contexto del documento hasta el momento(es decir h_{t-1}) y el último vector palabra observado x_t.

IV. REVISIÓN DE LITERATURA

Para la búsqueda se ah usado las plataformas Arxiv y el motor de búsqueda Google Académico.

IV-A. Cadena de Búsqueda

Las cadenas de búsqueda fueron las siguientes:

- **TITLE-ABS-KEY** (Dataset for reading comprehension, teaching machines to read, omitted word)
- **TITLE-ABS-KEY**(Long-Short-Term-Memories,RNN,NLP,Language Models)
- **ABS-ABS** (Dialog Models, CBT)

IV-B. Preguntas de Revisión

Las preguntas tomadas como referencia para este proyecto fueron:

- Pregunta 1: ¿Se puede enseñar a una máquina a leer y comprender?
- Pregunta 2: ¿Cómo funciona la red neuronal recurrente LSTM?
- Pregunta 3: ¿Cómo implementar un Dialog Models para la data CBT?

IV-C. Resultados de Revisión

Al iniciar la investigación, se tuvo que ver si era posible que las máquinas pudieran leer y comprender, en [1] nos muestran tres modelos con los cuales era posible la comprensión de lectora de artículos del CNN and Daily Mail, de tal manera que podía responder preguntas relacionadas a los artículos incluso con palabras del mismo omitidas. Dándonos una visión general de como se compondría un modelo de red neuronal para nuestro fin.

En [5], se hace mención de como es el funcionamiento de un LSTM, además de mostrarnos de manera intuitiva su diseño y la formulación matemática detrás de ella. Como se mostró en el diagrama de Long Short-Term Memory del Marco Teórico, se pueden observar algunas etapas del LSTM. Primero tenemos la nueva generación de memoria,que utilizando la palabra de entrada y el estado oculto genera una nueva memoria que incluye aspectos de la nueva palabra. Luego tendríamos una puerta de entrada que determinar si vale la pena preservar la memoria. Seguimos con la puerta olvidada que se encarga de calcular si seguimos ocupando memoria para producir una salida. Finalmente la puerta de salida separa la memoria final del estado oculto.

Encontramos un framework llamado ParlAI, en [3] se menciona los cincos principales directorios que el framework de ParlAI posee: core, agentes, ejemplos(contiene código para importar datasets, y entrenar y evaluar un modelo), tareas y mturk. Entre estos modelos que tiene como ejemplos se encuentra el modelo Sequence to Sequence que, como se menciona, toma una secuencia de inputs y reporta una secuencia de outputs. Los agentes creados en el código ejemplo tienen implementados los encode y decode de modelos LSTM.
La plataforma ParlAI cuenta también con un tutorial en Google Colab de como importar el dataset CBT así como editar el modelo Seq2Seq con este dataset a conveniencia del trabajo. Para el entrenamiento del modelo , se utiliza la clase TrainModel, la cual tiene parámetros como máximo tiempo de entrenamiento, tamaño del batch,etc. De esta manera se puede entrenar el modelo e ir probando la conveniencia de estos parámetros para el modelo.

V. ESTADO DEL ARTE:

En la actualidad existen novedosas arquitecturas de redes neuronales para tareas de comprensión lectora de la máquina. En esta sección describiremos algunas de estas.

V-A. Deep LSTM Reader

Deep LSTM Reader propuesto en el artículo Teaching Machines to Read and Comprehend [1] es un modelo que pone a prueba la capacidad de los Deep LSTM encoder para manejar secuencias largas de inputs. Este modelo se alimenta palabra por palabra de artículos del CNN al Deep LSTM encoder y luego con un delimitador también se introducen consultas al codificador. Como resultado, se obtiene un modelo que procesa cada par de consultas del artículo como una única secuencia larga. Dado el artículo y la consulta, el modelo predice el token del artículo que responde a la consulta.

V-B. ReasoNet

ReasoNet propuesto en el artículo ReasoNet: Learning to Stop Reading in Machine Comprehension [4] es una arquitectura de red neuronal llamada red de razonamiento la cual tiene el fin de realizar las tareas de comprensión de la máquina. Las ReasoNets hacen uso de múltiples giros para explotar eficientemente y razonar sobre la relación entre las consultas, los documentos y las respuestas. Con el uso de de aprendizaje por refuerzo, las ReasoNets pueden determinar dinámicamente continuar con el proceso de comprensión tras digerir los resultados intermedios, o terminar la lectura cuando concluye que la información existente es adecuada para producir una respuesta.

V-C. R-NET

ReasoNet propuesto en el artículo R-Net: Machine Reading Comprehension with self-matching networks [6] es un modelo de redes neuronales de extremo a extremo para responder a preguntas del estilo de la comprensión lectora, cuyo objetivo es responder a preguntas de un pasaje dado. En este artículo primero se empareja la pregunta y el pasaje con redes recurrentes basadas en la atención para obtener la representación del pasaje consciente de la pregunta. Luego propone un mecanismo de atención auto-ajustada para refinar la representación comparando el pasaje consigo mismo, lo que codifica eficazmente la información de todo el pasaje. Por último, emplea redes de punteros para localizar las posiciones de las respuestas de los pasajes.

VI. METODOLOGÍA:

En esta sección se describirá los pasos del desarrollo del proyecto y las herramientas necesarias;

VI-A. ParlAI

ParlAI es un framework de software de código abierto para la investigación de diálogos implementada en Python, disponible en http://parl.ai. Su objetivo es proporcionar un marco unificado para compartir, capacitar y probar modelos de diálogo; integración de Amazon Mechanical Turk para la recopilación de datos, la evaluación humana y el aprendizaje por refuerzo; además cuenta con un repositorio de modelos de aprendizaje automático para comparar con otros modelos y mejorar las arquitecturas existentes. También ofrece más de 20 tareas, incluye conjuntos de datos populares como SQuAD, bAbI tasks, MCTest, WikiQA, QACNN, QADailyMail, CBT, bAbI Dialog, Ubuntu, OpenSubtitles y VQA.

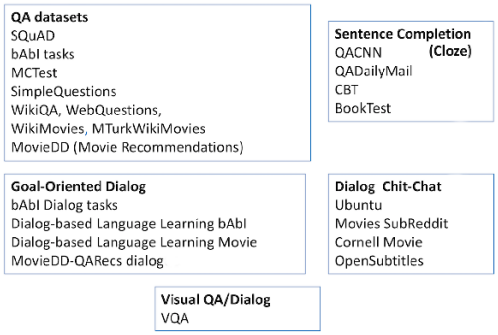

Figura 5. Tareas en la primera versión de ParlAI. Fuente: ParlAI: A Dialog Research Software Platform

Además de la amplia gama de datasets disponibles, ofrece una amplia gama de ayudantes para crear nuestros propios agentes.

ParlAI integra varios modelos, incluidos modelos neuronales como redes de memoria, Seq2seq y attentive LSTMs, los cuales implementaremos en este proyecto.

VI-B. Metología de Trabajo

Pasos a seguir para el desarrollo del proyecto:

1. Primeros instalamos el framework ParlAI
2. Importamos el dataset CBT
3. Implementamos los agente para el modelo
4. Creamos el modelo Seq2Seq
5. Entrenamos el modelo

VII. EXPERIMENTACIÓN Y RESULTADOS

VII-A. Arquitectura del Modelo

Se implementó un modelo Seq2seq el cual toma en la entrada una secuencia de palabras (oración u oraciones) y genera una secuencia de salida de palabras. Lo hará mediante el uso de la memoria a largo y corto plazo (LSTM). La arquitectura de este modelo tiene dos componentes principales, el codificador(Encoder) y el decodificador(Decoder).

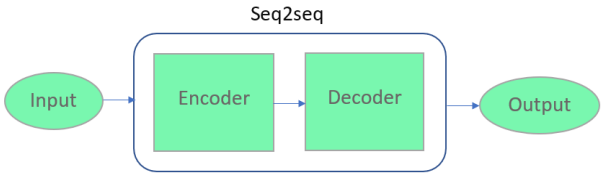

Figura 6. Arquitectura del Seq2seq
Fuente: Autoría propia

El Encoder convierte las palabras de entrada en vectores ocultos, cada vector representa la palabra actual y el contexto.

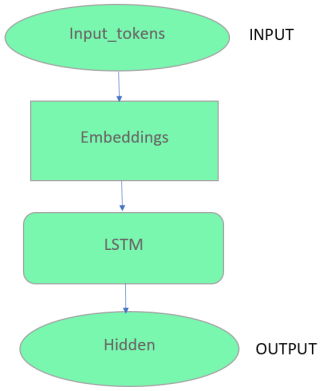

Figura 7. Arquitectura del Encoder
Fuente: Autoría propia

El Decoder toma como entrada el vector oculto generado por el codificador, sus estados ocultos y la palabra actual para producir el vector oculto y finalmente predecir la palabra resultante.

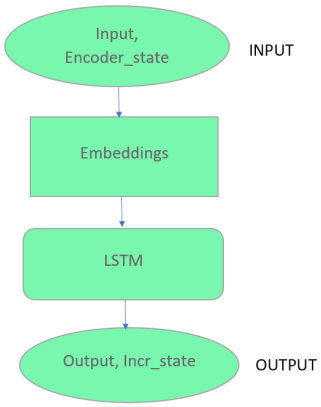

Figura 8. Arquitectura del Decoder
Fuente: Autoría propia

VII-A1. Defenición de variables dentro de las arquitecturas:

- Encoder: Modelo de codificación
- Decoder: Modelo de decodificación
- Input_tokens: Palabras entrantes, oración u oraciones tokenizadas
- Embeddings: Incrustaciones de palabras
- LSTM: Arquitectura de la RNN
- Hidden: Estados ocultos
- Input: tokens generados por el decodificador
- encoder_state: Estado del Encoder
- Output: Palabra predicha
- incr_state: Estado incremental del decodificador

VII-B. Conjunto de Datos

Para la evaluación del modelo se tomó el dataset Children'S Book Test (CBT), ya que este era el de menor tamaño y esto haría que el modelo cargue más rapido el dataset, en comparación a otros datasets conocidos como CNN y Daily Mail.

CBT es un dataset que está diseñado para medir directamente qué tan bien los modelos lingüísticos pueden explotar un contexto lingüístico más amplio, por esta razón la usaremos para que la máquina aprendar a leer y comprender. Cabe mencionar que la CBT se construye a partir de libros que están disponibles gratuitamente, gracias al Proyecto Gutenberg.

VII-C. Experimentación

Entrenamos el modelo limitandolo al timepo de entrenamiento, obtuvimos los siguientes resultados:

1. Para 10 minutos de entrenamiento
Evaluación para los datos de validación.

```
07:56:39 | valid:
          accuracy    bleu-4  clen  ctpb  ctps  ctrunc  ctrunclen  exps  exs     f1  gpu_mem  llen  loss     lr  ltpb  ltps
\
   all       .03812 3.813e-11 512.3  4098 15776       0          0 30.79 8000 .03812    .2582 2.013 5.521 .00053  16.1 61.98
   cbt:CN         0         0 522.1                   0          0       2000      0          2.004 5.885
   cbt:NE         0         0   489                   0          0       2000      0          2.047 7.136
   cbt:P     .1525 1.525e-10 528.9                   0          0       2000  .1525              2 3.809
   cbt:V          0         0 509.2                   0          0       2000      0              2 5.254
          ltrunc  ltrunclen   ppl  token_acc  token_em  total_train_updates  tpb   tps
   all         0          0 463.3      .5141    .03787                   80 4115 15838
   cbt:CN      0          0 359.7      .4968         0
   cbt:NE      0          0  1257      .4839         0
   cbt:P       0          0 45.12      .5757     .1515
   cbt:V       0          0 191.4      .5000         0
```

Figura 9. Tabla 1. Fuente: Autoría propia

Evaluación para los datos de test

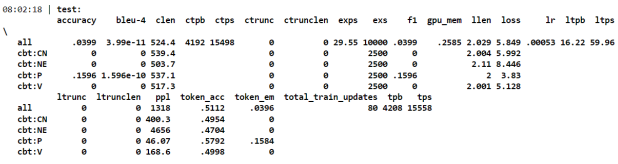

08:02:18 | test:	accuracy	bleu-4	clen	ctpb	ctps	ctrunc	ctrunclen	exps	exs	f1	gpu_mem	llen	loss	lr	ltpb	ltps
all	.0399	3.99e-11	524.4	4192	15498	0	0	29.55	10000	.0399	.2585	2.029	5.849	.00053	16.22	59.96
cbt:CN	0	0	539.4			0	0		2500	0		2.004	5.992			
cbt:NE	0	0	503.7			0	0		2500	0		2.11	8.446			
cbt:P	.1596	1.596e-10	537.1			0	0		2500	.1596		2	3.83			
cbt:V	0	0	517.3			0	0		2500	0		2.001	5.128			

	ltrunc	ltrunclen	ppl	token_acc	token_em	total_train_updates	tpb	tps
all	0	0	1318	.5112	.0396	80	4208	15558
cbt:CN	0	0	400.3	.4954	0			
cbt:NE	0	0	4656	.4704	0			
cbt:P	0	0	46.07	.5792	.1584			
cbt:V	0	0	168.6	.4998	0			

Figura 10. Tabla 2. Fuente: Autoría propia

2. Para 20 minutos de entrenamiento:
Evaluación para los datos de validación:

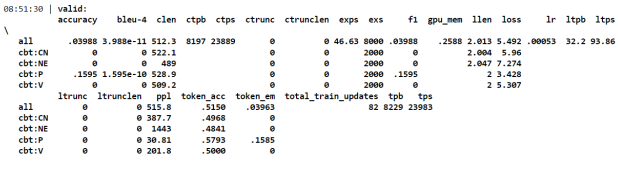

08:51:30 | valid:	accuracy	bleu-4	clen	ctpb	ctps	ctrunc	ctrunclen	exps	exs	f1	gpu_mem	llen	loss	lr	ltpb	ltps
all	.03988	3.988e-11	512.3	8197	23889	0	0	46.63	8000	.03988	.2588	2.013	5.492	.00053	32.2	93.86
cbt:CN	0	0	522.1			0	0		2000	0		2.004	5.96			
cbt:NE	0	0	489			0	0		2000	0		2.047	7.274			
cbt:P	.1595	1.595e-10	528.9			0	0		2000	.1595		2	3.428			
cbt:V	0	0	509.2			0	0		2000	0		2	5.307			

	ltrunc	ltrunclen	ppl	token_acc	token_em	total_train_updates	tpb	tps
all	0	0	515.8	.5150	.03963	82	8229	23983
cbt:CN	0	0	387.7	.4968	0			
cbt:NE	0	0	1443	.4841	0			
cbt:P	0	0	30.81	.5793	.1585			
cbt:V	0	0	201.8	.5000	0			

Figura 11. Tabla 3. Fuente: Autoría propia

Evaluación para los datos de test

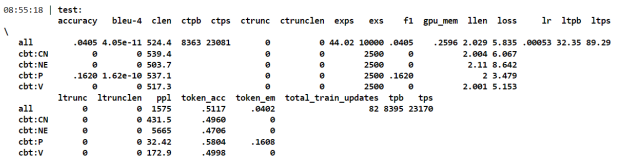

08:55:18 | test:	accuracy	bleu-4	clen	ctpb	ctps	ctrunc	ctrunclen	exps	exs	f1	gpu_mem	llen	loss	lr	ltpb	ltps
all	.0405	4.05e-11	524.4	8363	23081	0	0	44.02	10000	.0405	.2596	2.029	5.835	.00053	32.35	89.29
cbt:CN	0	0	539.4			0	0		2500	0		2.004	6.067			
cbt:NE	0	0	503.7			0	0		2500	0		2.11	8.642			
cbt:P	.1620	1.62e-10	537.1			0	0		2500	.1620		2	3.479			
cbt:V	0	0	517.3			0	0		2500	0		2.001	5.153			

	ltrunc	ltrunclen	ppl	token_acc	token_em	total_train_updates	tpb	tps
all	0	0	1575	.5117	.0402	82	8395	23170
cbt:CN	0	0	431.5	.4960	0			
cbt:NE	0	0	5665	.4706	0			
cbt:P	0	0	32.42	.5804	.1608			
cbt:V	0	0	172.9	.4998	0			

Figura 12. Tabla 4. Fuente: Autoría propia

3. Para 30 minutos de entrenamiento:
Evaluación para los datos de validación:

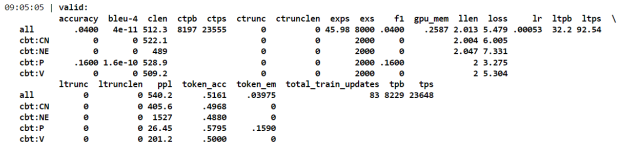

09:05:05 | valid:	accuracy	bleu-4	clen	ctpb	ctps	ctrunc	ctrunclen	exps	exs	f1	gpu_mem	llen	loss	lr	ltpb	ltps
all	.0400	4e-11	512.3	8197	23555	0	0	45.98	8000	.0400	.2587	2.013	5.479	.00053	32.2	92.54
cbt:CN	0	0	522.1			0	0		2000	0		2.004	6.005			
cbt:NE	0	0	489			0	0		2000	0		2.047	7.331			
cbt:P	.1600	1.6e-10	528.9			0	0		2000	.1600		2	3.275			
cbt:V	0	0	509.2			0	0		2000	0		2	5.304			

	ltrunc	ltrunclen	ppl	token_acc	token_em	total_train_updates	tpb	tps
all	0	0	540.2	.5161	.03975	83	8229	23648
cbt:CN	0	0	405.6	.4968	0			
cbt:NE	0	0	1527	.4880	0			
cbt:P	0	0	26.45	.5795	.1590			
cbt:V	0	0	201.2	.5000	0			

Figura 13. Tabla 5. Fuente: Autoría propia

Evaluación para los datos de test

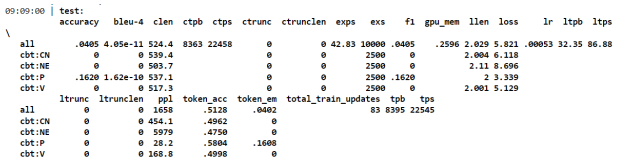

09:09:00 | test:	accuracy	bleu-4	clen	ctpb	ctps	ctrunc	ctrunclen	exps	exs	f1	gpu_mem	llen	loss	lr	ltpb	ltps
all	.0405	4.05e-11	524.4	8363	22458	0	0	42.83	10000	.0405	.2596	2.029	5.821	.00053	32.35	86.88
cbt:CN	0	0	539.4			0	0		2500	0		2.004	6.118			
cbt:NE	0	0	503.7			0	0		2500	0		2.11	8.696			
cbt:P	.1620	1.62e-10	537.1			0	0		2500	.1620		2	3.339			
cbt:V	0	0	517.3			0	0		2500	0		2.001	5.129			

	ltrunc	ltrunclen	ppl	token_acc	token_em	total_train_updates	tpb	tps
all	0	0	1658	.5128	.0402	83	8395	22545
cbt:CN	0	0	454.1	.4962	0			
cbt:NE	0	0	5979	.4750	0			
cbt:P	0	0	28.2	.5804	.1608			
cbt:V	0	0	168.8	.4998	0			

Figura 14. Tabla 6. Fuente: Autoría propia

4. Para 40 minutos de entrenamiento:

Evaluación para los datos de validación

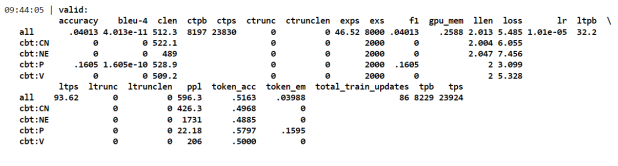

09:44:05 | valid:	accuracy	bleu-4	clen	ctpb	ctps	ctrunc	ctrunclen	exps	exs	f1	gpu_mem	llen	loss	lr	ltpb	ltps
all	.04013	4.013e-11	512.3	8197	23830	0	0	46.52	8000	.04013	.2588	2.013	5.485	1.01e-05	32.2	93.62
cbt:CN	0	0	522.1			0	0		2000	0		2.004	6.055			
cbt:NE	0	0	489			0	0		2000	0		2.047	7.456			
cbt:P	.1605	1.605e-10	528.9			0	0		2000	.1605		2	3.099			
cbt:V	0	0	509.2			0	0		2000	0		2	5.328			

	ltrunc	ltrunclen	ppl	token_acc	token_em	total_train_updates	tpb	tps
all	0	0	596.3	.5163	.03988	86	8229	23924
cbt:CN	0	0	426.3	.4968	0			
cbt:NE	0	0	1731	.4885	0			
cbt:P	0	0	22.18	.5797	.1595			
cbt:V	0	0	206	.5000	0			

Figura 15. Tabla 7. Fuente: Autoría propia

Evaluación para los datos de test

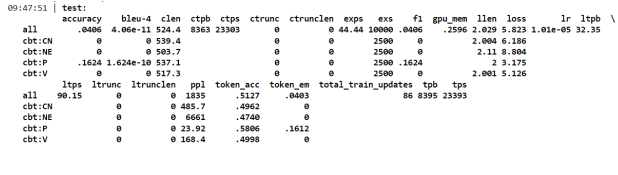

09:47:51 | test:	accuracy	bleu-4	clen	ctpb	ctps	ctrunc	ctrunclen	exps	exs	f1	gpu_mem	llen	loss	lr	ltpb	ltps
all	.0406	4.06e-11	524.4	8363	23303	0	0	44.44	10000	.0406	.2596	2.029	5.823	1.01e-05	32.35	90.15
cbt:CN	0	0	539.4			0	0		2500	0		2.004	6.186			
cbt:NE	0	0	503.7			0	0		2500	0		2.11	8.804			
cbt:P	.1624	1.624e-10	537.1			0	0		2500	.1624		2	3.175			
cbt:V	0	0	517.3			0	0		2500	0		2.001	5.126			

	ltrunc	ltrunclen	ppl	token_acc	token_em	total_train_updates	tpb	tps
all	0	0	1835	.5127	.0403	86	8395	23393
cbt:CN	0	0	485.7	.4962	0			
cbt:NE	0	0	6661	.4740	0			
cbt:P	0	0	23.92	.5806	.1612			
cbt:V	0	0	168.4	.4998	0			

Figura 16. Tabla 8. Fuente: Autoría propia

5. Para 80 minutos de entrenamiento:
Evaluación para los datos de validación

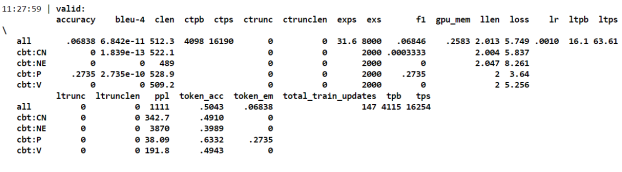

11:27:59 | valid:	accuracy	bleu-4	clen	ctpb	ctps	ctrunc	ctrunclen	exps	exs	f1	gpu_mem	llen	loss	lr	ltpb	ltps
all	.06838	6.842e-11	512.3	4098	16190	0	0	31.6	8000	.06846	.2583	2.013	5.749	.0010	16.1	63.61
cbt:CN	0	1.839e-13	522.1			0	0		2000	.0003333		2.004	5.837			
cbt:NE	0	0	489			0	0		2000	0		2.047	8.261			
cbt:P	.2735	2.735e-10	528.9			0	0		2000	.2735		2	3.64			
cbt:V	0	0	509.2			0	0		2000	0		2	5.256			

	ltrunc	ltrunclen	ppl	token_acc	token_em	total_train_updates	tpb	tps
all	0	0	1111	.5043	.06838	147	4115	16254
cbt:CN	0	0	342.7	.4910	0			
cbt:NE	0	0	3870	.3989	0			
cbt:P	0	0	38.09	.6332	.2735			
cbt:V	0	0	191.8	.4943	0			

Figura 17. Tabla 9. Fuente: Autoría propia

Evaluación para los datos de test

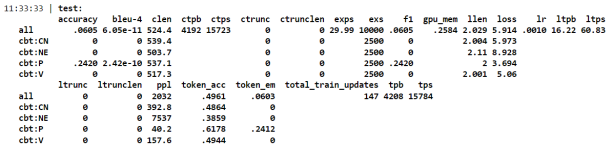

```
11:33:33 | test:
          accuracy   bleu-4  clen  ctpb  ctps  ctrunc  ctrunclen  exps   exs    f1  gpu_mem  llen  loss    lr  ltpb  ltps
   all        .0605 6.05e-11 524.4  4192 15723       0          0 29.99 10000 .0605    .2584 2.029 5.914 .0010 16.22 60.83
   cbt:CN        0        0 539.4                   0          0        2500     0          2.004 5.973
   cbt:NE        0        0 503.7                   0          0        2500     0          2.11 8.928
   cbt:P      .2420 2.42e-10 537.1                   0          0        2500 .2420             2 3.694
   cbt:V         0        0 517.3                   0          0        2500     0          2.001  5.06
          ltrunc  ltrunclen   ppl  token_acc  token_em  total_train_updates  tpb   tps
   all         0          0  2032      .4961     .0603                  147 4208 15784
   cbt:CN      0          0 392.8      .4864        0
   cbt:NE      0          0  7537      .3859        0
   cbt:P       0          0  40.2      .6178     .2412
   cbt:V       0          0 157.6      .4944        0
```

Figura 18. Tabla 10. Fuente: Autoría propia

VIII. Análisis

Observamos las tablas 1, 3, 5, 7 y 9 para el análisis de la métrica accuracy que nos da la precisión del modelo. Analizando las tablas obtenidas al entrenar el modelo con los datos de evaluación cambiando el tiempo de entrenamiento para 10, 20, 30, 40 y 80 minutos, sus accuraccys respectivos son de 3.812 %, 3.988 %, 4.000 %, 4.013 % y 6.838 %; se nota un incremento del accuracy a medida que aumentamos el tiempo de entrenamiento.

Ahora observamos las tablas 2, 4, 6, 8 y 10 para el análisis de la métrica accuracy que nos da la precisión del modelo. Analizando las tablas obtenidas al entrenar el modelo con los datos de test cambiando el tiempo de entrenamiento para 10, 20, 30, 40 y 80 minutos, sus accuraccys respectivos son de 3.990 %, 3.988 %, 4.050 %, 4.060 % y 6.050 %; se nota un incremento del accuracy a medida que aumentamos el tiempo de entrenamiento.

Ambos incrementos del accuracy ocurrieron por la modificación del máximo tiempo de ejecución del entrenamiento, ya que esto hizo que el modelo aprenda más y se beneficie, aumentando su precisión.

IX. Conclusiones

Se logró comprender como trabajan las RNN en diferentes modelos y como estas permiten que las máquinas sean capaces de aprender a leer y comprender.

- Se logró implementar el modelo Seq2Seq en el ParlAI para poder leer y comprender un libro para niños.
- Se concluyó que el modelo Seq2Seq implementado necesita más tiempo de entrenanmiento para obtener mejores resultados.

Referencias

[1] Teaching machines to read and comprehend. *Avances en los sistemas de procesamiento de información neuronal*.

[2] Uday Kamath, John Liu, and James Whitaker. *Deep learning for NLP and speech recognition*, volume 84. Springer, 2019.

[3] Alexander H Miller, Will Feng, Adam Fisch, Jiasen Lu, Dhruv Batra, Antoine Bordes, Devi Parikh, and Jason Weston. Parlai: A dialog research software platform. *arXiv preprint arXiv:1705.06476*, 2017.

[4] Yelong Shen, Po-Sen Huang, Jianfeng Gao, and Weizhu Chen. Reasonet: Learning to stop reading in machine comprehension. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1047–1055, 2017.

[5] Richard Socher and Richard Socher Mundra. Cs 224d: Deep learning for nlp4. 2015.

[6] Wenhui Wang, Nan Yang, Furu Wei, Baobao Chang, and Ming Zhou. R-net: Machine reading comprehension with self-matching networks. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 189–198, 2017.